

Universidad de Costa Rica
Escuela de Ingeniería Eléctrica
IE0435 - Inteligencia Artificial Aplicada a la Ingeniería Eléctrica

Documento base para presentación individual

Opciones gratuitas o de bajo costo para acceder a LLMs a través de APIs

Tema 11

Duración sugerida: 8 a 12 minutos de exposición + 3 minutos de actividad breve

Base teórica: AI.pdf del curso. Referencia práctica inicial: artículo de Medium sobre Hugging Face y Llama 3.

1. Propósito del documento

Este documento sirve como base para construir la presentación individual sobre opciones gratuitas o de bajo costo para acceder a modelos grandes de lenguaje, o LLMs, mediante APIs. La idea no es solamente explicar una lista de servicios, sino conectar el tema con la materia del curso: inteligencia artificial, aprendizaje automático, redes neuronales, deep learning, aplicaciones en ingeniería eléctrica y uso ético de herramientas de IA.

La asignación pide presentar principios, modelos o algoritmos relevantes, relacionar el tema con el curso y compartir opciones para utilizar modelos fundacionales desde código por medio de llamadas de API. También se debe indicar al final qué herramientas de IA se usaron y cuáles prompts se emplearon.

2. Objetivo general y objetivos específicos

Objetivo general

Explicar cómo se puede acceder a modelos grandes de lenguaje mediante APIs gratuitas o de bajo costo, comparando opciones actuales y relacionando su uso con los conceptos de inteligencia artificial y redes neuronales estudiados en el curso.

Objetivos específicos

- Definir qué es un LLM y por qué se considera una aplicación moderna del aprendizaje profundo.
- Explicar qué es una API y cómo permite usar modelos fundacionales desde código sin entrenarlos localmente.
- Comparar opciones como Hugging Face, GroqCloud, Gemini API y Together AI según facilidad de uso, costo, modelos disponibles y limitaciones.
- Relacionar el uso de LLMs con aplicaciones de ingeniería eléctrica, como documentación técnica, análisis de datos, programación y asistencia en interpretación de información.
- Reconocer limitaciones técnicas y éticas: privacidad, alucinaciones, dependencia del proveedor y uso transparente de IA generativa.

3. Introducción: por qué este tema importa

Los modelos grandes de lenguaje han cambiado la forma en que se interactúa con la inteligencia artificial. Antes, para usar un modelo avanzado era común necesitar hardware especializado, instalar bibliotecas complejas o incluso entrenar modelos propios. Hoy, muchos modelos se pueden usar desde código mediante una API. Esto permite que estudiantes, investigadores y desarrolladores prueben modelos de lenguaje desde Python o JavaScript sin ejecutar el modelo localmente.

En el contexto de ingeniería eléctrica, esto es relevante porque muchas tareas del trabajo técnico involucran texto, documentación, código y análisis de información: revisar hojas de datos, resumir artículos, generar reportes, programar scripts de análisis, interpretar registros de mantenimiento o preparar material educativo. Un LLM no reemplaza la validación técnica ni las mediciones reales, pero puede funcionar como una herramienta de apoyo para acelerar procesos.

El punto central de la presentación es mostrar cómo acceder a esos modelos de forma práctica, barata o gratuita, y al mismo tiempo explicar qué hay detrás de ellos desde la teoría del curso.

4. Base teórica desde el curso

4.1 Inteligencia artificial como herramienta de ingeniería

En el AI.pdf, la inteligencia artificial se aborda con un enfoque práctico: se presentan algoritmos, alcances, limitaciones y problemas específicos dentro de la ingeniería eléctrica. Esta perspectiva es importante porque el tema de APIs para LLMs no se debe presentar como una moda aislada, sino como una forma moderna de usar herramientas computacionales inteligentes en tareas reales.

De forma general, la IA puede entenderse como el desarrollo de sistemas artificiales capaces de mostrar comportamientos asociados con la inteligencia: reconocer patrones, clasificar datos, predecir valores, buscar soluciones, optimizar decisiones o interactuar mediante lenguaje natural. Los LLMs se ubican dentro de esta última área: procesamiento y generación de lenguaje natural.

4.2 Relación con aprendizaje automático

El aprendizaje automático, o machine learning, busca que una computadora aprenda a partir de datos. En vez de programar manualmente todas las reglas, se ajusta un modelo con ejemplos. En el curso se estudian problemas como clasificación, regresión, agrupamiento, búsqueda y optimización. Estos problemas sirven para entender cómo los modelos de IA toman entradas, procesan información y entregan una salida.

Un LLM también sigue esa lógica general: recibe una entrada, procesa internamente la información y genera una salida. La diferencia es que trabaja con lenguaje natural y fue entrenado con enormes cantidades de texto y código. Por eso puede responder preguntas, resumir, traducir, generar texto o asistir en programación.

4.3 Redes neuronales artificiales

Las redes neuronales artificiales son una base importante de la inteligencia artificial moderna. En su forma más sencilla, como el perceptrón, reciben datos de entrada, los multiplican por pesos internos y generan una salida. El aprendizaje ocurre cuando esos pesos se ajustan para reducir el error entre la salida obtenida y la salida esperada.

Dicho de forma simple: una red neuronal aprende modificando números internos llamados pesos. Si una entrada es más importante para la respuesta, el peso asociado puede aumentar; si aporta poco o genera error, se ajusta en sentido contrario. Este proceso se repite muchas veces durante el entrenamiento.

4.4 Perceptrón multicapa y deep learning

El perceptrón simple tiene limitaciones, sobre todo cuando el problema no se puede separar de forma lineal. Por eso se utilizan redes con más capas, conocidas como perceptrones multicapa o MLP. Estas redes tienen una capa de entrada, una o varias capas ocultas y una capa de salida. Las capas ocultas permiten transformar la información y representar relaciones más complejas.

Cuando se emplean redes neuronales con muchas capas se habla de aprendizaje profundo o deep learning. En el AI.pdf se explica que el deep learning utiliza redes con varias capas de neuronas, donde cada capa puede verse como una etapa de abstracción. Esto permite abordar problemas complejos, aunque aumenta la cantidad de pesos, el costo computacional y la dificultad de entrenamiento.

4.5 Del deep learning a los LLMs

Los LLMs son una aplicación moderna del deep learning. No son perceptrones simples, sino modelos neuronales profundos con una arquitectura mucho más compleja. La arquitectura dominante en los LLMs modernos es el transformer, propuesto en el artículo "Attention Is All You Need". La idea central del

transformer es el mecanismo de atención, que permite al modelo identificar relaciones importantes entre partes de una secuencia de texto.

En vez de procesar el texto palabra por palabra de forma rígida, el transformer puede asignar mayor peso a las partes del contexto que son más relevantes para generar la respuesta. Esto ayuda a que los modelos trabajen con instrucciones largas, preguntas, código y documentos.

4.6 Modelos fundacionales

Un modelo fundacional es un modelo grande entrenado previamente con enormes cantidades de datos y que luego puede usarse en muchas tareas distintas. La ventaja es que el usuario no tiene que entrenar el modelo desde cero. Entrenar un LLM desde cero requiere grandes bases de datos, muchas GPU, personal especializado y costos elevados. En cambio, con una API se puede usar un modelo ya entrenado desde una aplicación propia.

5. Conceptos clave para entender las APIs de LLMs

5.1 ¿Qué es una API?

Una API, o Application Programming Interface, es una interfaz que permite que un programa se comunique con otro sistema. En este caso, la API permite que un programa escrito en Python, JavaScript u otro lenguaje envíe una solicitud a un modelo de lenguaje alojado en servidores externos y reciba una respuesta generada por el modelo.

En una llamada típica a una API de LLM se envía:

- El nombre del modelo que se desea usar.
- El prompt o instrucción del usuario.
- Parámetros de generación, como temperatura, máximo de tokens o formato de salida.
- Una clave de acceso o API key, que identifica al usuario.
- Opcionalmente, mensajes de sistema, historial de conversación o herramientas externas.

5.2 Flujo básico de uso

1. El usuario escribe un prompt desde su código.
2. El código envía una solicitud HTTP al proveedor de la API.
3. El proveedor ejecuta el modelo en sus servidores.
4. El modelo genera la respuesta.
5. La API devuelve el texto generado al programa del usuario.

5.3 ¿Qué son los tokens?

Los LLMs no procesan texto exactamente como palabras completas, sino como unidades llamadas tokens. Un token puede ser una palabra, parte de una palabra, un signo o un fragmento de texto. Las APIs normalmente miden el consumo según tokens de entrada y tokens de salida. Esto importa porque muchos planes gratuitos tienen límites de uso, y los planes pagos cobran según el número de tokens procesados.

Ejemplo simple: si se envía un prompt muy largo y se pide una respuesta muy extensa, se consumen más tokens. Por eso, para usar APIs de bajo costo conviene escribir instrucciones claras, evitar texto innecesario y limitar la longitud de la respuesta cuando sea posible.

5.4 Parámetros comunes de generación

Parámetro	Descripción
-----------	-------------

temperature	Controla qué tan variable o creativa será la respuesta. Valores bajos producen respuestas más deterministas; valores altos generan mayor variedad.
max_tokens	Limita la cantidad máxima de tokens que puede generar el modelo.
top_p	Controla la diversidad de la respuesta mediante muestreo probabilístico.
system prompt	Define el rol o comportamiento general del modelo, por ejemplo: “responda como asistente técnico”.
streaming	Permite recibir la respuesta poco a poco, útil para aplicaciones interactivas.

6. Referencia práctica inicial: artículo de Medium

El profesor menciona como referencia inicial un artículo de Medium titulado “How to Access Free Open Source LLMs Like Llama 3 from Hugging Face Using Python API Step-by-Step”. Este artículo es útil porque muestra el camino práctico para empezar: crear una cuenta en Hugging Face, generar un token, escoger un modelo y hacer una llamada desde Python.

Para la presentación, esta fuente se puede usar como ejemplo de implementación, no como base teórica principal. La base teórica conviene tomarla del AI.pdf, mientras que el artículo sirve para demostrar cómo se pasa de la teoría a una llamada real desde código.

La idea que se puede decir en la exposición es: “El artículo recomendado muestra una forma concreta de consumir un modelo abierto desde Hugging Face usando Python. A partir de ese ejemplo se amplía la comparación a otras opciones gratuitas o de bajo costo”.

7. Opciones gratuitas o de bajo costo para acceder a LLMs mediante APIs

A continuación se resumen algunas opciones útiles para estudiantes o proyectos pequeños. Los precios y límites pueden cambiar, por lo que siempre se debe revisar la documentación oficial antes de usar una opción en un proyecto real.

Opción	Tipo de modelos	Ventajas	Limitaciones	Cuándo conviene
Hugging Face Inference Providers	Muchos modelos abiertos y modelos de distintos proveedores	Amplia variedad de modelos, integración con Python y JavaScript, buen punto de entrada para modelos open source	El rendimiento y disponibilidad dependen del proveedor/modelo; algunos modelos requieren pago o límites	Cuando se quiere aprender, probar modelos abiertos y comparar alternativas
GroqCloud	Modelos abiertos optimizados para inferencia rápida	Muy rápido para respuestas tipo chat, API compatible con estilo OpenAI, útil para demos	El plan gratuito tiene límites de uso y la lista de modelos puede cambiar	Cuando se necesita velocidad y facilidad para una demo o prototipo
Gemini API	Modelos comerciales de Google,	Buena documentación, API key desde AI	El acceso gratuito tiene límites y condiciones;	Cuando se quiere una opción comercial con

	multimodales según versión	Studio, SDK oficial para Python, JavaScript, Go y Java	algunos modelos avanzados requieren pago	documentación sólida y buen soporte multimodal
Together AI	Modelos abiertos mediante inferencia serverless y endpoints dedicados	Amplia oferta de modelos abiertos, precios por millón de tokens, opciones para escalar	Puede requerir revisar costos por modelo; no todo es gratuito	Cuando se quiere experimentar con varios modelos abiertos y luego escalar

7.1 Hugging Face

Hugging Face es una de las plataformas más conocidas para trabajar con modelos abiertos. Su ecosistema permite buscar modelos, revisar tarjetas de modelo, probar inferencia y usar APIs mediante SDKs. Para el tema de la presentación, es importante porque conecta muy bien con el artículo recomendado por el profesor.

Ventaja principal: permite experimentar con muchos modelos open source y aprender el flujo completo de uso de una API. Desventaja principal: no todos los modelos están disponibles gratis sin límites, y el comportamiento puede depender del proveedor de inferencia seleccionado.

7.2 GroqCloud

GroqCloud se enfoca en inferencia rápida. Para una presentación corta, es atractivo porque permite mostrar respuestas rápidas usando modelos abiertos desde una API. Además, su documentación permite usar una estructura compatible con clientes tipo OpenAI, lo que facilita adaptar código existente.

Ventaja principal: velocidad y facilidad para demos. Desventaja principal: el uso gratuito está limitado por restricciones de tasa y disponibilidad de modelos.

7.3 Gemini API

Gemini API es la opción de Google para acceder a sus modelos desde código. La documentación oficial permite crear una API key desde Google AI Studio y usar el SDK Google GenAI en Python, JavaScript/TypeScript, Go y Java. También ofrece compatibilidad con bibliotecas estilo OpenAI en ciertos casos.

Ventaja principal: documentación sólida, facilidad para empezar y capacidades multimodales según el modelo. Desventaja principal: los límites gratuitos y precios dependen del modelo y del nivel de uso.

7.4 Together AI

Together AI ofrece inferencia serverless, endpoints dedicados y acceso a distintos modelos abiertos. Su página de precios presenta costos por millón de tokens, lo cual ayuda a comparar cuánto costaría usar un modelo en una aplicación real.

Ventaja principal: variedad de modelos y escalabilidad. Desventaja principal: para usarlo bien hay que revisar el costo exacto por modelo, porque no todos tienen el mismo precio.

8. ¿Cómo escoger una opción?

Para escoger una API no basta con preguntar cuál es “la mejor”. Conviene comparar según el caso de uso:

- Para aprender y probar modelos abiertos: Hugging Face.

- Para una demo rápida con baja latencia: GroqCloud.
- Para una opción comercial documentada y multimodal: Gemini API.
- Para experimentar con varios modelos abiertos y escalar: Together AI.
- Para proyectos con datos sensibles: revisar privacidad, retención de datos y condiciones del proveedor antes de enviar información.

También se deben considerar los siguientes criterios técnicos:

- Costo por tokens o límites del plan gratuito.
- Modelos disponibles y tamaño del contexto.
- Velocidad de respuesta.
- Compatibilidad con Python o JavaScript.
- Privacidad y manejo de datos.
- Estabilidad de la API y documentación.
- Facilidad para cambiar de proveedor si el proyecto crece.

9. Relación con ingeniería eléctrica

Aunque los LLMs trabajan principalmente con texto, pueden apoyar tareas comunes en ingeniería eléctrica. Algunos ejemplos útiles para mencionar en la presentación son:

- Generación de scripts en Python para procesar datos de sensores, mediciones o simulaciones.
- Resumen de hojas de datos, artículos técnicos o manuales de equipos.
- Apoyo en redacción de reportes, bitácoras y documentación de proyectos.
- Explicación de conceptos de redes neuronales, clasificación, regresión, control o procesamiento de señales.
- Asistencia para interpretar resultados de modelos de mantenimiento predictivo o detección de anomalías.
- Creación de interfaces tipo chatbot para consultar documentación técnica interna.

El punto importante es dejar claro que el LLM no sustituye el criterio técnico. En ingeniería eléctrica siempre se deben verificar cálculos, mediciones, simulaciones y normas. El LLM sirve como asistente para organizar información, generar borradores y acelerar tareas repetitivas.

10. Limitaciones y riesgos

El uso de APIs de LLMs tiene ventajas, pero también riesgos que deben presentarse con claridad.

10.1 Privacidad

Cuando se usa una API, el texto enviado sale de la computadora del usuario hacia servidores externos. Por eso no se deben enviar contraseñas, claves, información personal, datos confidenciales de una empresa ni documentos sensibles sin revisar las políticas del proveedor.

10.2 Alucinaciones

Un LLM puede generar información incorrecta con apariencia convincente. Esto se conoce como alucinación. En trabajos técnicos, cualquier resultado debe verificarse con fuentes confiables, simulaciones, cálculos o documentación oficial.

10.3 Dependencia del proveedor

Los modelos disponibles, límites gratuitos y precios pueden cambiar. Si una aplicación depende completamente de un proveedor, un cambio de política puede afectar el proyecto. Por eso conviene diseñar el código de manera que sea posible cambiar de proveedor cuando sea necesario.

10.4 Sesgos y responsabilidad

Los modelos aprenden de datos creados por personas y pueden reflejar sesgos, errores o tendencias presentes en esos datos. Por eso, el uso de IA debe ser responsable, especialmente cuando se utiliza para tomar decisiones que afectan a personas o procesos críticos.

Referencias:

- Coto Jiménez, M. (2026). Introducción a los Modelos Clásicos de Inteligencia Artificial Aplicada a la Ingeniería Eléctrica. Universidad de Costa Rica. Documento del curso AI.pdf.
- Universidad de Costa Rica, Escuela de Ingeniería Eléctrica. (2026). Asignación: Presentación Individual, Tema 11: Opciones gratuitas o de bajo costo para acceder a LLMs a través de APIs. presentacion11.pdf.
- Paddalwar, Y. How to Access Free Open Source LLMs Like Llama 3 from Hugging Face Using Python API Step-by-Step. Medium. <https://medium.com/@yashpaddalwar/how-to-access-free-open-source-llms-like-llama-3-from-hugging-face-using-python-api-step-by-step-5da80c98f4e3>
- Hugging Face. Inference Providers documentation. <https://huggingface.co/docs/inference-providers/en/index>
- Hugging Face. Pricing and Billing for Inference Providers. <https://huggingface.co/docs/inference-providers/pricing>
- Groq. GroqCloud Pricing. <https://groq.com/pricing>
- Google AI for Developers. Gemini API documentation and quickstart. <https://ai.google.dev/gemini-api/docs>
- Google AI for Developers. Gemini API quickstart. <https://ai.google.dev/gemini-api/docs/quickstart>
- Together AI. Pricing. <https://www.together.ai/pricing>
- Together AI Docs. Serverless models. <https://docs.together.ai/docs/serverless-models>
- Vaswani, A., et al. (2017). Attention Is All You Need. Advances in Neural Information Processing Systems. <https://arxiv.org/abs/1706.03762>